

教育 AI 交互证据的可信评价：Score 与 Evidence Support 分离报告 (Submission Candidate)

Development Only. 本文所有数值来自 70 条 AI_PROVISIONAL 开发标注, `annotation_status=DEVELOPMENT_ONLY`, `formal_gate_eligible=false`。项目另有 70/70 条 AI_ASSISTED 开发标注, 但它同样是 DEVELOPMENT_ONLY, 不是 HUMAN_R1 或 HUMAN_R2, 也未作为本文正式输入。当前 HUMAN_R1=0/70 VALID、HUMAN_R2=0/70、FORMAL_HUMAN_GATE=NOT_RUN。文中结果用于说明方法行为与识别边界, **不是**正式研究结论、统计置信区间、AI 因果效应、正式 AIV 或学生排名。

底稿: `reports/paper/competition_paper_narrative_draft.md`; 数字唯一来源: `reports/verification/core_numbers_source_of_truth.json`。

摘要

AI 进入学习过程后, 学生提交的文本混合了学生自身思考、AI 提示与重组、上下文缺失和标注不确定性。本文把问题定位为测量与可识别性问题, 而非预测问题: 先判断哪些记录构成可判读的学生 Evidence, 再在透明假设参数下同时报告 Score (ABL、HOT、Gap) 与 Evidence Support (effective evidence weight、effective coverage)。当有效证据权重为零时, 模型返回 NO_EFFECTIVE_EVIDENCE, 而不是 0 分。开发数据 (70 条 AI_PROVISIONAL 记录, 16 条可判读 Evidence, 693 个参数组合, 其中 33 个无定义) 显示: Raw 与 Adjusted 的 ABL/HOT/Gap 都保持为 3.5625 / 0.375 / 1.125, 但 effective evidence weight 从 16 降到 6, effective coverage 从 0.228571 降到 0.085714; 在更宽的敏感性范围内, coverage 最低达到 0.0057。核心结论是: **Score 数值稳定, 不代表支持它的 Evidence Support 稳定。**

1. Problem Background

AI 已经进入学习过程。评价者看到的是多种生成过程混合形成的结果, 而不是可直接等同于学生能力的纯粹观测。**看到学生提交了什么, 不等于观察到了多少可信的学生证据。**只对最终文本打分, 可能把 AI 的引导结构误当作学生的独立表现; 只报告一个稳定分数, 则可能掩盖支撑分数的有效 Evidence 已经非常稀薄。

本研究的 AIV 定位是形成性教学诊断, 不解释为学生长期稳定能力、无 AI 学习增益或 AI 的因果效果, 也不用于高风险排名。

2. Research Question

在学生证据受到 prompt 引导、上下文缺失和标注不确定性影响时, 如何构建一个**不把不可识别问题伪装成精确估计**的评价框架?

1. 哪些观察记录可以保留为可判读的 Student Evidence?
2. 在透明、可审查的偏差假设下, Score 与 Evidence Support 的可行范围如何变化?
3. 证据不足时, 如何返回“无定义”, 而不是填入看似完整的 0 分?

3. Why Traditional Evaluation Fails: Measurement Problem

DEVELOPMENT ONLY · AI_PROVISIONAL · formal_gate_eligible=false

这首先是 measurement / identifiability problem。预测方法假设目标与标签已明确，而本问题更早一层：学生文本中哪些成分可归因于学生，哪些可能来自 AI 引导，哪些记录因上下文不足或来源不可判而不进入有效证据。边界未确认时，更复杂的模型只会更精确地拟合一个混合标签。

开发数据的证据分层（70 条）：

类别	条数	处理
可判读 Evidence (L1–L6)	16	进入 Score 计算
NO_EVIDENCE	19	不进入，不视为低分
UNDETERMINED	35	不进入，不推断补齐

NO_EVIDENCE、UNDETERMINED 与可判读 Evidence 不混用。

4. Data and Measurement Boundary

16 条可判读 Evidence 全部具有 prompt_induced=true、context_truncated=false、confidence=medium、task_actor=ai。数据中不存在对照变化，因此无法估计 prompt、context 或 confidence 修正系数的唯一值。

本文采用 Partial Identification / Bounds：不假设修正系数已知，而是在透明参数集合 Θ 上计算结果：

- $\lambda_{\text{prompt}} \in [0, 1]$ ，步长 0.05（21 个值）
- $\lambda_{\text{context}} \in [0, 1]$ ，步长 0.10（11 个值）
- $r_{\text{medium}} \in \{0.5, 0.75, 1.0\}$

共 $21 \times 11 \times 3 = 693$ 个参数组合。所得区间是 **assumption-based identification interval**，不是统计置信区间，参数也不是估计或校准值。

5. Mathematical Model

对每条记录 i 定义可靠性权重：

$$w_i(\theta) = I(\text{student_evidence_bloom}_i \in L1...L6) \\ \cdot c_i(r_{\text{medium}}) \\ \cdot (1 - \lambda_{\text{prompt}} \cdot \text{prompt}_i) \\ \cdot (1 - \lambda_{\text{context}} \cdot \text{context}_i)$$

- $I(\cdot)$ ：只有可判读 Evidence 进入；NO_EVIDENCE、UNDETERMINED 的权重为 0，但仍计入分母 N 。
- c_i ：透明可靠性惩罚，high=1，medium= r_{medium} ，low=0.5。
- prompt_i 、 context_i ：prompt 引导与上下文截断的指示变量。

Score（结果层），仅在 $\sum w_i > 0$ 时定义：

$$\text{ABL}(\theta) = \sum w_i \cdot \text{Bloom}_i / \sum w_i \\ \text{HOT}(\theta) = \sum w_i \cdot I(\text{Bloom}_i \geq L4) / \sum w_i$$

$$\text{Gap}(\theta) = \sum w_i \cdot (\text{Task}_i - \text{Bloom}_i) / \sum w_i$$

DEVELOPMENT ONLY · AI_PROVISIONAL · formal_gate_eligible=false

Evidence Support (支持层) :

$$\begin{aligned} \text{effective evidence weight} &= \sum w_i \\ \text{effective coverage} &= \sum w_i / N, \quad N = 70 \text{ (全部 development records)} \end{aligned}$$

effective coverage 的分母是全部 70 条 development records，不是 16 条可判读 Evidence。 因此 coverage 同时反映 “有多少记录可判读” 和 “可判读记录在假设下保留多少权重” 。

无定义规则： $\sum w_i = 0$ 时返回 NO_EFFECTIVE_EVIDENCE，ABL/HOT/Gap 为 undefined under assumption，不平滑、不插值、不填 0。

公共缩放命题：若所有可判读 Evidence 的 (confidence, prompt, context) 取值相同，则 $w_i = k(\theta) \cdot l_i$ ， $k(\theta)$ 在分子分母中约去，Score 与 θ 无关，而 $\sum w_i = 16 \cdot k(\theta)$ 随 θ 变化。这是代数结构，不是经验发现，更不是因果效应。

6. Development Results and Counterexamples (Development Only)

基线 $\theta_0 = (\text{lambda_prompt}=0, \text{lambda_context}=0, \text{r_medium}=0.75)$:

指标	值	层
ABL	3.5625	Score
HOT	0.375	Score
Gap	1.125	Score
effective evidence weight	12.0 (=16×0.75)	Support
effective coverage	0.1714 (=12.0/70)	Support

693 个参数组合中，660 个有定义，33 个无定义。有定义组合上的结果：

指标	最小	最大
ABL	3.5625	3.5625
HOT	0.375	0.375
Gap	1.125	1.125
effective evidence weight	0.4	16.0
effective coverage	0.0057	0.2286

(Score 的极差仅为浮点误差量级，约 1e-16。)

Figure 4 (reports/development/core_figure_4_bounds_support.svg) : 横轴为 lambda_prompt，固定 lambda_context=0.00、r_medium=0.75。红线为归一化 Score，保持 1.00；蓝线为 effective coverage，从 0.1714 下降。在 lambda_prompt=1.00 处标记 NO_EFFECTIVE_EVIDENCE，Score 不绘制。

解释：当前 16 条可判读 Evidence 的参数相关字段完全相同，满足第 5 节公共缩放条件，所以 Score 稳定是**结构必然**，不能解释为模型稳健性或 prompt 的因果作用。

7. Sensitivity / Ablation

1. **无定义边界**：33 个无定义组合全部位于 $\lambda_{\text{prompt}}=1.0$ (11 个 $\lambda_{\text{context}} \times 3$ 个 r_{medium})。此时 16 条 Evidence 的 prompt 因子全部为 0，返回 NO_EFFECTIVE_EVIDENCE。
2. **Support 的敏感性**：effective weight 在有定义组合上的中位数为 5.8，四分位数为 3.15 与 8.85。Support 对假设高度敏感，Score 则不敏感。
3. **独立复算**：src/verification/recompute_bounds.py 不依赖主实现，独立复现了 70/16/693/660/33 及全部边界值。
4. **异质性检查**：现有真实开发数据中，可判读 Evidence 的 prompt、context 和 confidence 均无变化，**不支持**异质 Evidence 的经验对比。本文没有修改标注，也没有构造合成数据冒充真实结果。
5. **可复现性**：完整开发链路在隔离副本中重跑后，20 个产物与仓库版本逐字节一致（见 reports/submission/reproduction_notes.md）。

8. Human Validation Status and Limitations

当前没有正式人工验证结果：HUMAN R1 为 0/70 VALID，HUMAN R2 为 0/70，Formal Human Gate 为 NOT_RUN。AI_ASSISTED 文件的 70/70 完成度只表示机器辅助开发完成度，不改变本文 AI_PROVISIONAL / DEVELOPMENT_ONLY 的数据身份，也不能产生正式 reliability、AIV 或排名。

当前**不能**宣称：正式研究结论；学生真实或长期能力；prompt/agent 的因果效应；正式 AI 增量价值或正式 AIV；学生排名或高风险决策依据。

1. 正式人工 R1/R2 未完成，Gate 未产生结论。R2 为同一标注者的 test-retest，不是评分者间一致性。
2. 可判读 Evidence 缺少 prompt_induced=false、context_truncated=true、low/high confidence 和非 AI actor 的支持。
3. 完全分离结构可能混合了 selection、标注规则、临时标签和字段映射效应，不能解释为 prompt 修正效应。
4. 缺少独立的无 AI 学习 outcome、可靠原生 session_id 和可比 treatment/control。
5. 70 条开发结果不能外推到 140 条正式人工标注。
6. r_{medium} 与各 λ 只是透明假设范围，不是校准参数。

9. Practical Interpretation and Demo

Demo: reports/demo/index.html (读取 reports/demo/demo_payload.json, 需通过本地 HTTP 服务打开)。

1. 顶部横幅显示 DEVELOPMENT_ONLY · AI_PROVISIONAL；
2. 展示 70 条记录中有 16 条进入 L1-L6；
3. 拖动 λ_{prompt} 、 λ_{context} 、 r_{medium} ；
4. 同时显示 Score (ABL/HOT/Gap) 与 Evidence Support (effective weight / 70 development records)；
5. $\lambda_{\text{prompt}}=1$ 时状态变为 NO_EFFECTIVE_EVIDENCE，Score 不显示为 0。

正式切换流程见 handoff/FORMAL_GATE_SWITCH.md: 人工 R1/R2 → test-retest → Gate → Gate PASS
后以 --mode formal 重跑 → 替换本文 Development Only 表格。

10. Conclusion

在 AI 辅助学习中，可信评价不能只报告分数是否稳定，还必须报告支撑分数的学生证据是否存在、可判读且足够充分。开发数据展示了这种分离：Raw 与 Adjusted 的 Score 都为 3.5625 / 0.375 / 1.125，但 effective evidence weight 从 16 降到 6，coverage 从 0.228571 降到 0.085714；在完整敏感性范围内，coverage 还可降到 0.0057，并在极端假设下变为 NO_EFFECTIVE_EVIDENCE。**Score 数值稳定，不代表支持它的 Evidence Support 稳定。** 以上结论只描述方法行为；正式效果须等人工 Gate 通过后验证。

附录 A：数字来源

数字	来源文件
70 / 16 / 19 / 35	reports/verification/raw_input_recount.json
693 / 660 / 33、Score 与 Support 边界	reports/verification/core_numbers_source_of_truth.json
基线 12.0 / 0.1714	reports/development/partial_identification_grid.csv
Gate 状态 PENDING	reports/annotation_gate_report.json